

Finansta Biliřim Teknolojileri

Proje Ödevi Ara Raporu


1306210041

Ömer Faruk Koçoğlu

Bölüm 1: Problem Tanımı:

Seçilen Problemin Açıklaması

Geleneksel kredi skrolama sistemleri, yalnızca geçmiş kredi hareketleri ve gelir durumu gibi sınırlı veri ile manuel veya basit istatistikler ile analiz yaparak çalışmaktadır. Ancak bu yöntem yetersiz ve yavaştır, gizli risk belirtilerini/örüntülerini kaçıır ve kredi geçmişli olmayan potansiyel müşterileri sistemin dışında bırakır. Günümüzde bankalar ve FinTech kuruluşları, çok daha geniş veri setlerini analiz edebilen Yapay zekâ ve Makine Öğrenmesi modellerine geçiş yapmaktadır. Aşağıdaki tabloda görebileceğiniz üzere bankaların yapay zeka kullanım oranındaki artış başarılı kredi skrolamalarını büyük oranda etkilemektedir.



Source: ECB Banking Supervision.

Buna karşın, yapay zekâ tabanlı skrolama sistemleri çözdükleri problemlerin yanında yeni bir sorun yaratmıştır: "Kara Kutu" problemi. Yüksek doğrulukla çalışan derin öğrenme veya karmaşık ağaç tabanlı modeller, bir müşterinin kredisini reddederken kararın arkasındaki mantığı şeffaf bir şekilde sunmakta zorlanmaktadır. Dolayısıyla seçilen problem sadece başarılı değil aynı zamanda argüman olarak sunulabilecek seviyede anlaşılır veri verebilmelidir. Kısacası, problem geleneksel kredileme sisteminin derinlik olarak yetersiz kalıp başarı oranının yapay zekâ tabanlı algoritmalara göre daha düşük olması ve bu teknolojilere geçmeyen bankaların geri kalmasıdır.

Problemin Önemi

Avrupa Merkez Bankası ve Tüketici Finansal Koruma Bürosu gibi küresel regülatörler kullanımının finansal kurumlara verimlilik ve düşük temerrüt oranları sağladığını kabul etmekle birlikte, model şeffaflığını zorunlu tutmaktadır. Siyah kutu modeller, Apple Card örneğinde olduğu gibi, tarihsel verilerdeki önyargıları öğrenerek belirli gruplara karşı algoritmik ayrımcılık yapma riski taşır. Ayrıca, ekonomik koşulların değişmesiyle modellerin zamanla yaşadığı performans kaybı finansal kurumlar için ciddi derecede sermaye kayıplarına neden olabilir. Bu yüzden, geliştirilecek sistemin teknik olarak başarılı aynı zamanda şeffaf, müşteri güvenini sarsmayan ve Avrupa Birliğinin planladığı gibi yaklaşmakta olan regülasyonlara uyumlu olmalıdır. Nitekim projede temel düzeyde bir modelleme yapılacak olsa da iş gerçek finansa geldiğinde regülasyonlar ve müşteriler önceliklendirilmelidir ki bu da problemin ciddiyet ve önemini arttırmaktadır.

Çalışmanın Amacı

Çalışmanın temel amacı, Kaggle "Give Me Some Credit" veri setini kullanarak, müşterilerin temerrüde düşme olasılığını geleneksel yöntemlerden daha yüksek bir hassasiyetle tahmin edecek AI tabanlı bir kredi skorlama mekanizması tasarlamaktır. Proje bu hedefe ulaşmak için, gerekli makine öğrenimi adımlarını kapsamaktadır.

İlk aşamada, ham veri seti üzerinde detaylı bir keşifsel veri analizi yapılarak eksik verilerin ve aykırı değerlerin finansal standartlara uygun şekilde ön işleme tutulması amaçlanmaktadır. Kredi veri setlerinin karakteristik bir problemi olan sınıf dengesizliği/temerrüde düşen azınlık sınıfı ile düzenli ödeyen çoğunluk sınıfı arasındaki orantısızlık uygun istatistiksel veya algoritmik yaklaşımlar çözülecektir.

Modelin başarısı, salt genel doğruluk oranıyla değil; finansal risk yönetiminde daha kritik olan AUC-ROC, Kesinlik ve Duyarlılık metrikleri üzerinden değerlendirilecektir. Bankalar için riskli bir müşteriye kredi vermenin (yanlış negatif) maliyeti, risksiz bir müşteriyi reddetmekten (yanlış pozitif) çok daha yüksek olduğu için, modelin tahmin eşiklerinin bu maliyeti minimize edecek şekilde optimize edilmesi hedeflenmektedir.

Genel amaç olarak, sisteme yeni bir müşterinin finansal parametreleri girildiğinde, arka planda bu veriyi işleyerek onay, ret veya İnceleme kararlarını somut bir risk skoru ile döndüren çalışan bir makine öğrenimi modeli üretmektir.

Bölüm 2: Veri Seti

Veri Kaynağı

Projede kullanılan veri seti, Kaggle platformunda finansal risk analizi amacıyla sunulan "Give Me Some Credit" yarışmasına aittir. Makine öğrenmesi algoritmalarının eğitimi ve testi için kullanılacak olan ana veri seti (cs-training.csv), yaklaşık 150.000 müşterinin geçmiş finansal hareketlerini ve demografik bilgilerini içermektedir.

Veri İçeriği

Veri setinde 1 adet hedef değişken ve 10 adet bağımsız değişken bulunmaktadır:

- **SeriousDlqin2yrs:** Müşterinin 90 gün veya daha uzun süreli temerrüde düşüp düşmeyeceği.
- **RevolvingUtilizationOfUnsecuredLines:** Toplam kredi kartı ve teminatsız kredi limitlerinin doluluk oranı.
- **age:** Müşterinin yaşı.
- **NumberOfTime30-59DaysPastDueNotWorse:** Son 2 yıl içinde 30 ile 59 gün arası gecikmiş ödeme sayısı.
- **DebtRatio:** Aylık borç ödemeleri ve yaşam giderlerinin, aylık brüt gelire oranı.
- **MonthlyIncome:** Aylık brüt gelir.
- **NumberOfOpenCreditLinesAndLoans:** Açık kredi hesabı veya kredi kartı sayısı.
- **NumberOfTimes90DaysLate:** Son 2 yılda 90 gün veya daha fazla gecikmiş ödeme sayısı.
- **NumberRealEstateLoansOrLines:** İpotekli konut kredisi gibi gayrimenkul kredisi sayısı.
- **NumberOfTime60-89DaysPastDueNotWorse:** Son 2 yıl içinde 60 ile 89 gün arası gecikmiş ödeme sayısı.
- **NumberOfDependents:** Müşterinin bakmakla yükümlü olduğu kişi sayısı

Veri Ön İşleme Adımları

Sistemde çalıştırılan Python ile yapılan Keşifsel Veri Analizi sonucunda aşağıdaki yapısal problemler tespit edilmiş olup, modelleme öncesi şu adımlarla giderilecektir:

1. **Eksik Veri:** Analiz çıktısında görüldüğü üzere MonthlyIncome kolonunda 29.731 ve NumberOfDependents kolonunda 3.924 adet kayıp gözlem bulunmaktadır.

Dağılımın çarpıklığı hesaplanarak veriler ilgili sütunların ortanca değerleri ile doldurulacaktır.

2. **Sınıf Dengesizliği:** Hedef değişkende temerrüde düşmeyenler %93,3, temerrüde düşenler ise yalnızca %6,68 oranındadır. Bu, algoritma içindeki ağırlıklandırma parametreleri modifiye edilerek çözülecektir.
3. **Aykırı Değer Yönetimi:** DebtRatio gibi oranlarda veri giriş hatasından kaynaklanan aşırı uç değerler istatistiksel sınırlar ile baskılanacaktır.

Aşağıdaki görselde sisteme yüklenen ham verinin eksik değer ve sınıf dağılımı analizi çıktısı yer almaktadır:

```
--- EKSİK VERİ ---  
MonthlyIncome      29731  
NumberOfDependents  3924  
dtype: int64  
  
--- SINIF DAĞILIMI (%) ---  
SeriousDlqin2yrs  
0      93.316  
1       6.684  
Name: proportion, dtype: float64  
PS C:\Users\user\Desktop\finans_proje>
```

Örnek Veri Seti

Modelin eğitileceği veri setinin genel yapısını ve feature formatını gösteren ilk 10 satırlık veri aşağıdadır.

--- İlk 10 satır ---	RevolvingUtilizationOfUnsecuredLines	age	NumberOfTime30-59DaysPastDueNotHorse	DebtRatio	MonthlyIncome	NumberOfOpenCreditLinesAndLoans	NumberOfTimes90DaysLate	NumberRealEstateLoansOrLines	NumberOfTime60-89DaysPastDueNotHorse
0	1	0.766127	45	2	0.882982	9120.0	13	0	0
1	2.0	0.957151	40	0	0.121876	2600.0	4	0	0
2	1.0	0.658188	38	1	0.005113	3042.0	2	1	0
3	0.0	0.233818	30	0	0.636850	3300.0	5	0	0
4	0.0	0.907239	49	1	0.624926	6358.0	7	0	1
5	0.0	0.213179	74	0	0.375687	3500.0	3	0	1
6	1.0	0.385682	57	0	5710.000000	NaN	8	0	3
7	0.0	0.754464	39	0	0.209940	3500.0	8	0	0
8	0.0	0.116951	27	0	46.000000	NaN	2	0	0
9	NaN	0.189169	57	0	0.688291	23684.0	9	0	4
10	2.0								

Bölüm 3: Yöntem / Model

Kullanılan Modeller

Projede, kredi skortlama probleminin çözümünde sektör standartlarına uygun olarak iki farklı metodoloji kullanılacaktır:

1. **Decision Tree Based Models**
2. **Logistic Regression**

Model Seçimi Gerekçesi Model seçim süreci, Avrupa Merkez Bankası (ECB) tarafından 2024 yılında paylaşılan "AI's impact on banking" raporundaki sektör verilerine dayandırılmıştır.



Source: ECB Banking Supervision.

- **Sektörel Trend ve Performans:** Grafikte görüldüğü üzere, kredi skorlama amacıyla kullanılan yapay zeka metodolojileri arasında "Karar ağacı tabanlı modeller" açık ara en çok tercih edilen yöntemdir ve incelenen 13 bankanın 8'i bu yöntemi kullanmaktadır. Bu modellerin tercih edilme nedeni, tabular verilerdeki yüksek tahmin gücü ve değişkenler arasındaki karmaşık ilişkileri yakalayabilme yeteneğidir. Projemizde bu kategoriye temsil etmek üzere modern ve hızlı bir algoritma olan **LightGBM** seçilmiştir.
- **Şeffaflık ve Karşılaştırma:** Grafik incelendiğinde, Logistic Regression yönteminin halen en çok tercih edilen ikinci yöntem olduğu görülmektedir. Bu yöntem, sonuçların açıklanabilirliği ve finansal regülasyonlara uyumu açısından kritik bir temeldir.
- **Neden Neural Networks Değil?:** Grafikte Neural Network kullanımının kredi skorlama tarafında sadece 1 banka tarafından olduğu görülmektedir. Bunun temel sebebi, sinir ağlarının yapısal verilerde aşırı öğrenme eğilimi ve karar mekanizmasının kara kutu olarak kalmasıdır.

Bu veriler ile proje, sektördeki en başarılı iki yöntemi ele alarak geliştirilecektir.

Bölüm 4: Uygulama


Geliştirilen Sistemin Açıklaması:

Müşterilerin finansal verilerini girdi olarak alarak eğitilmiş makine öğrenmesi modelleri aracılığıyla temerrüt olasılığını hesaplayan bir risk skorlama sistemi geliştirilmiştir. Sistem, anlık veri üzerinde ön işleme uygulayarak, 0 ile 1 arasında bir sonuç üretir. Bu skor üzerinden sistem otomatik olarak üç farklı karar mekanizması işletir: Düşük risk için "Onay", sınırda kalan riskler için "İnceleme" ve yüksek risk için "Ret".

Sistem Mimarisi

1. **Veri ve Eğitim Katmanı:** Verilerin belleğe alındığı ve SimpleImputer kullanılarak eksik değerlerin medyan ataması ile doldurulduğu yapısal hazırlık katmanı.
2. **Inference Engine:** Eğitilmiş modelin belleğe alındığı ve yeni/canlı verinin modele beslenerek risk skorunun üretildiği mantıksal katman.
3. **Kullanıcı Arayüzü:** Dinamik test profillerini ve manuel girdi seçeneklerini barındıran, sistemin ürettiği kararı (Onay, İnceleme, Ret) ilgili risk skoruyla birlikte gösteren terminal tabanlı interaktif katman.

Flow-chart



Kullanılan Teknolojiler

- Programlama Dili: Python
- Veri Manipülasyonu ve Analizi: Pandas, NumPy
- Makine Öğrenmesi Kütüphaneleri: Scikit-learn, LightGBM

Bölüm 5: Sonuç

Performans Metrikleri

Finansal risk modellemesinde sınıf dengesizliğinin (%93 ödeyen, %7 temerrüt) yaratacağı yanıltıcı doğruluk oranlarını bertaraf etmek amacıyla, modellerin performansı doğruluk Accuracy üzerinden değil; Duyarlılık Recall ve AUC-ROC metrikleri baz alınarak ölçülmüştür.

Model Performans Sonuçları

1. Lojistik Regresyon:

- a. Recall: %66,03
- b. AUC-ROC: %80,32

2. LightGBM (Geliştirilen Ana Model):

- a. Recall: %76,96
- b. AUC-ROC: %86,72

Değerlendirme ve Tartışma

Elde edilen sonuçlar analiz edildiğinde, karar ağacı tabanlı modelin, Lojistik Regresyon'a teknik üstünlük sağladığı görülmektedir.

KAYNAKÇA:

- **Avrupa Merkez Bankası (ECB) Raporu:** Singh, S., Schupbach, A., Asiala, A., & Siwecki, D. A. (2025, 20 Kasım). *AI's impact on banking: use cases for credit scoring and fraud detection*. European Central Bank.
- **Sektörel İnceleme Makalesi:** KITRUM. (Tarih Yok). *AI Credit Scoring: How It Works and Why It Matters for Lenders*. [[AI Credit Scoring: How It Works and Why It Matters for Lenders - KITRUM](#)]
- **Yapay Zeka Aracı:** Google. (2026). *Gemini* (21 Mayıs versiyonu) [Büyük dil modeli]. <https://gemini.google.com> (Not: Veri analizi kodlarının oluşturulması, hata ayıklama ve rapor metinlerinin akademik formata dönüştürülmesi süreçlerinde destek aracı olarak kullanılmıştır.)